

# Logistic 回归 & Softmax 回归

## ⑬ 熵, KL 距离与 LR 回归

相对熵(概率⑧)中,  $p(x)$  是样本分布,  $q(x)$  是我们建模时定义的一个简单分布, 如何度量  $q(x)$  与  $p(x)$  的接近程度呢?

→ 使用相对熵(KL-距离)来定义.

$$KL = \sum_x p(x) \ln \frac{p(x)}{q(x)}$$

$$= \sum_x p(x) (\ln p(x) - \ln q(x)) = \sum_x p(x) \ln p(x) - \sum_x p(x) \ln q(x)$$

$$= \underbrace{H(x)}_{\text{样本的信息熵, 固定值, 可忽略}} \left[ - \sum_x p(x) \ln q(x) \right] \leftarrow \text{优化目标, 希望 } - \sum_x p(x) \ln q(x) \text{ 取最小值.}$$

→ 如何求  $-\sum_x p(x) \ln q(x)$  的最小值.

在 LR 中, 似然概率  $q(x) = q(\theta^T x) = \frac{1}{1 + e^{-\theta^T x}}$   
↓  
 sigmoid 函数

而  $-\sum_x p(x) \ln q(x) = -\sum_i y^{(i)} \cdot \ln \frac{1}{1 + e^{-\theta^T x^{(i)}}}$

$\underbrace{p(x)}_{\text{样本概率}} \underbrace{\ln q(x)}_{\text{似然概率}}$

这也就是  $\left\{ \begin{array}{l} \text{正例 } y^{(i)}=1 \\ \text{负例 } y^{(i)}=0 \end{array} \right\}$  时的对数似然函数  
 来自正例

→ 相对熵取最小值  $\Leftrightarrow$  对数似然取最小值

$\Leftrightarrow$  正对数似然函数取最大值

参考

LR & Softmax ⑬

→ ~~取正例  $y^{(i)}=1$  负例  $y^{(i)}=-1$  改算正对数似然函数~~

同理. 把正例负例都考虑进来  
 得到正对数似然函数

$\underbrace{L(\theta)}_{\text{Likelihood}} = \ln L(\theta) = \sum_{i=1}^m \left( y^{(i)} \ln \frac{1}{1 + e^{-\theta^T x^{(i)}}} + (1 - y^{(i)}) \ln \left( 1 - \frac{1}{1 + e^{-\theta^T x^{(i)}}} \right) \right)$

→ 因此, 求解这个正对数似然函数的最大值,

就等价于求解相对熵的最小值.

# ④ 拉格朗日对偶性

④ 用途: 约束条件下求极值, 支持向量机, 最大熵模型

④ 原始问题: 求解目标 约束条件

$$\textcircled{*} \min_{x \in R^n} f(x) \quad \text{s.t.} \quad \begin{matrix} C_i(x) \leq 0 & i=1, \dots, k \\ h_j(x) = 0 & j=1, 2, \dots, l \end{matrix}$$

$f(x), C_i(x), h_j(x)$  都在  $R^n$  上连续可微

④ 引入拉格朗日函数:

$$L(x, \alpha, \beta) = f(x) + \sum_{i=1}^k \alpha_i \boxed{C_i(x)} + \sum_{j=1}^l \beta_j \boxed{h_j(x)}$$

$\downarrow$  拉格朗日因子  $\alpha_i \geq 0$        $\downarrow$  拉格朗日乘子 对正负无要求

因此可推导出

$$L(x, \alpha, \beta) \leq f(x)$$

④ 定义:  $\boxed{Q_p(x) = \max_{\alpha, \beta: \alpha_i \geq 0} L(x, \alpha, \beta)}$ , 则求  $\min_x f(x)$  等价于求  $\min_x Q_p(x)$

④ 问题:  $\min_x Q_p(x) = \min_x \max_{\alpha, \beta: \alpha_i \geq 0} L(x, \alpha, \beta) = \min_x f(x)$

即: 原始问题最优解为  $p^* = \min_x Q_p(x)$

④ 对偶问题:

④ 定义  $\boxed{Q_D(\alpha, \beta) = \min_x L(x, \alpha, \beta)}$ , 再对这个定义式求极大值.

④ 对偶问题:  $\max_{\alpha, \beta: \alpha_i \geq 0} Q_D(\alpha, \beta) = \max_{\alpha, \beta: \alpha_i \geq 0} \min_x L(x, \alpha, \beta)$  原问题的对偶问题.

④ 如果原问题, 对偶问题都有最优解, 则有

$$d^* = \max_{\alpha, \beta: \alpha_i \geq 0} \min_x L(x, \alpha, \beta) \quad // \text{对偶问题 } Q_D(\alpha, \beta)$$

$$\leq \min_x \max_{\alpha, \beta: \alpha_i \geq 0} L(x, \alpha, \beta) = p^* \quad // \text{原问题 } Q_p(x)$$

证明:

$$\because Q_D(\alpha, \beta) = \min_x L(x, \alpha, \beta) \leq L(x, \alpha, \beta) \leq \max_{\alpha, \beta: \alpha_i \geq 0} L(x, \alpha, \beta) = Q_p(x)$$

$$\therefore Q_D(\alpha, \beta) \leq Q_p(x)$$

又  $\because Q_D(\alpha, \beta)$  和  $Q_P(x)$  都有最优解

$$\therefore \max_{\alpha, \beta; \alpha_i \geq 0} Q_D(\alpha, \beta) \leq \min_x Q_P(x)$$

<d> KKT条件: 为了使对偶问题的最优解, 也是原始问题的最优解,

必须满足 KKT 条件 (充要条件)

条件 1:  $f(x), C_i(x), h_j(x)$  全部连续可导,

(1~3) 这样才能对  $\mathcal{L}(x, \alpha, \beta) = f(x) + \sum_{i=1}^k \alpha_i C_i(x) + \sum_{j=1}^l \beta_j h_j(x)$  关于  $x, \alpha_i, \beta_j$

求偏导, 令  $\nabla_x \mathcal{L}(x^*, \alpha^*, \beta^*) = 0, \nabla_{\alpha} \mathcal{L}(x^*, \alpha^*, \beta^*) = 0,$

$$\nabla_{\beta} \mathcal{L}(x^*, \alpha^*, \beta^*) = 0$$

条件 2: 存在  $\alpha_i^*, x^*$ , 使得对  $\forall i \in [1, k], \alpha_i^* C_i(x^*) = 0$

(4)  $\alpha_i^* \geq 0, C_i(x^*) \leq 0$  (约束条件), 同时要让不等式  $\leq$  取等号  $\sum_{i=1}^k \alpha_i^* C_i(x^*)$

必须等于 0, 又因为  $\alpha_i^* C_i(x^*) \leq 0$ , 因此只能让每个  $\alpha_i^* C_i(x^*) = 0$ .

条件 3:  $C_i(x^*) \leq 0, h_j(x^*) = 0$  原始约束条件

条件 4:  $\alpha_i \geq 0$  来自拉格朗日乘子法定义

<e> 为什么要用对偶问题求原始问题的最优解.

当对偶问题求解比原始问题简单时.