

2. 数学分析

① \log 函数: $y = \log_e x$ $\frac{dy}{dx} = \frac{1}{x}$ $x=1$ 时 $\log_e x$ 斜率为 1



② 求极限

③ 单调递增有上界的函数 \Rightarrow 有极限

④ 导数: 一阶导数反映曲线变化的快慢; 二阶导数反映斜率变化的快慢, 表征曲线的凸凹性, 加速度总是向着曲线凹的一面

⑤ 常用的导数:

$$C' = 0 \quad (x^n)' = nx^{n-1} \quad (\sin x)' = \cos x \quad (\cos x)' = -\sin x$$

$$(a^x)' = a^x \ln a \quad (e^x)' = e^x \quad (\log_a x)' = \frac{1}{x} \log_a e \quad (\ln x)' = \frac{1}{x}$$

$$(u+v)' = u' + v' \quad (uv)' = u'v + v'u$$

⑥ 积分可以看作导数的逆运算: 对导数求积分就是函数本身
对积分求导数也是函数本身

⑦ 分部导数公式 \Leftrightarrow 分部积分公式

$$(uv)' = u'v + uv' \quad \Leftrightarrow \int f(x) dx = \frac{f(x) \cdot x}{(u \ v)'} - \int x df(x)$$

$$f(x) \cdot x = \int f(x) dx + \int x df(x)$$

⑧ 幂指函数 $f(x) = x^x$ 求极值.

函数先降后升, 如何求最小值.

$$\ln(f(x)) = \ln(x^x)$$

两边求导 $\rightarrow \frac{1}{f(x)} f'(x) = \ln x + 1$

令导数为 0 $\rightarrow \ln x + 1 = 0$

$$x = e^{-1} \quad \text{中得验证点}$$

$$\ln(x) = e^{-1}$$

\Rightarrow 再求二阶导, 证明验证点是极值

⑨ $\ln(N!)$ 数量级是 $N \ln N - N$

$$\begin{aligned}\ln(N!) &= \sum_{i=1}^N \ln i \approx \int_1^N \ln x \, dx \\ &= x \ln x \Big|_1^N - \int_1^N x \, d \ln x \quad \text{"分部积分公式" } \Rightarrow \text{数分⑦} \\ &= N \ln N - \int_1^N x \frac{1}{x} \, dx \\ &= N \ln N - x \Big|_1^N \\ &= N \ln N - N\end{aligned}$$

⑩ 泰勒展开式, 麦克劳林展开式

泰勒: $f(x) = f(x_0) + f'(x_0)(x-x_0) + \frac{f''(x_0)}{2!}(x-x_0)^2 + \dots + \frac{f^{(n)}(x_0)}{n!}(x-x_0)^n + R_n(x)$

麦克劳林: $f(x) = f(0) + f'(0)(x-0) + \frac{f''(0)}{2!}(x-0)^2 + \dots + \frac{f^{(n)}(0)}{n!}x^n + o(x^n)$

函数在某个点 $x=x_0$ 处 n 阶可导, 就可利用泰勒展开式展开, 在 $x=0$ 处 n 阶可导就可利用麦克劳林展开式展开

⑪ 求 $\sin x, e^x, \dots$ 的极值: 用泰勒展开式求极值

⑫ 求 Gini 系数: 用泰勒展开式求值.

$\sum_{k=1}^K P_k(1-P_k)$: Gini 系数其实是熵公式中的 $\ln(x)$ 在 $x=1$ 处一阶展开

$$\text{熵 } H(x) = - \sum_{k=1}^K P_k \ln P_k = \sum_{k=1}^K P_k (-\ln P_k)$$

$$\approx \sum_{k=1}^K P_k (1-P_k) \leftarrow f(x) = -\ln(x) \text{ 在 } x=1 \text{ 处一阶展开}$$

忽略高阶无穷小

⑬ 方向导数: $z = f(x, y)$ 在点 (x, y) 可微, 则函数在该

点任一方向导数都存在, φ 记为 ~~该方向与 x 轴的夹角~~ 转角.

x 轴到方向 l 的



$$\frac{\partial f}{\partial l} = \frac{\partial f}{\partial x} \cos \varphi + \frac{\partial f}{\partial y} \sin \varphi = \begin{bmatrix} \frac{\partial f}{\partial x} \\ \frac{\partial f}{\partial y} \end{bmatrix} \cdot \begin{bmatrix} \cos \varphi \\ \sin \varphi \end{bmatrix}$$

⑭ 对任意方向 \vec{d} , 何时^在方向 \vec{d} 上导数最大: \vec{d} 与 \vec{L} 方向相同时, \Rightarrow 用于梯度下降

⑮ 梯度: $z = f(x, y)$ 在平面区域 D 内具有一阶连续偏导数

对区域内每个点 $P(x, y)$, 向量

向量 $\left(\frac{\partial f}{\partial x}, \frac{\partial f}{\partial y}\right)$ 为 $z = f(x, y)$ 在点 P 的梯度, 记做 $\text{grad} f(x, y)$

梯度方向是函数在该点变化最快的方向

⑯ Euler (欧拉 Γ 函数): 阶乘在实数域上的推广

$$\Gamma(x) = (x-1) \Gamma(x-1)$$

$$\Gamma(x) = \int_0^{+\infty} \underbrace{t^{x-1}}_{\text{普通幂函数}} \underbrace{e^{-t}}_{\text{普通指数函数}} dt = (x-1)!$$

普通幂函数与普通指数函数相乘。

⑰ 凸函数 (convex)

$\forall x, y \in \text{dom } f, 0 \leq \theta \leq 1$, 有

$$f(\theta x + (1-\theta)y) \leq \theta f(x) + (1-\theta)f(y)$$

一阶可微时: 凸函数充要条件是任意一点, 函数值大于等于经过该点的切线

二阶可微时: 凸函数充要条件是二阶导数为正 (对一元函数) 或二阶梯度矩阵正定 (对多元函数)

e.g. $f(x, y) = 3x^2 + 4y^2 - xy$

$$\nabla f = \begin{pmatrix} 6x - y \\ 8y - x \end{pmatrix}$$

对 x, y 求偏导

~~XXXXXX~~

Hessian 矩阵

二阶梯度矩阵

$$H = \begin{pmatrix} \frac{\partial^2 f}{\partial x^2} & \frac{\partial^2 f}{\partial x \partial y} \\ \frac{\partial^2 f}{\partial y \partial x} & \frac{\partial^2 f}{\partial y^2} \end{pmatrix} = \begin{pmatrix} 6 & -1 \\ -1 & 8 \end{pmatrix}$$

⑱ 正定: 正数在 N 维空间的推广

一阶主子式 $6 > 0$

⑲ 凸函数举例

指数 $f(x) = e^{ax}$

幂 $f(x) = x^a \quad a \in \mathbb{R} \quad a > 1 \text{ 或 } a \leq 0$

负对数 $f(x) = -\ln x$

最大值 $f(\vec{x}) = \max_{(x_1, x_2, \dots, x_n)} \dots$ 二阶顺序主子式 $47 > 0$

范数 $f(\vec{x}) = \|\vec{x}\|$

指数函数 $f(\vec{x}) = \log(e^{x_1} + e^{x_2} + \dots + e^{x_n})$

2 概率论 & 贝叶斯

① ^{PDF} $P(X=x)$: 概率, 概率分布率/概率质量 (离散函数), 概率密度 (连续函数)

$P(X=x) = 0$ 不代表一定不发生, 这是一个求极限的概念

② ^{CDF} 累积分布函数, $\Phi(x) = P(X \leq x_0)$

对于连续函数 $\Phi(x) = P(X \leq x_0) = \int_{-\infty}^{x_0} P(x) dx$

对于离散函数 $\Phi(x) = P(X \leq x_0) = \sum_{x=-\infty}^{x_0} P(x)$

离散分布

值域在 $[0, 1]$ 的单调递增函数, 有可能是概率函数, 例如

sigmoid 函数 $F(x) = \frac{1}{1+e^{-x}}$ ($x \in (-\infty, +\infty)$)


③ 古典概率 $P(A) = P_N^n / N^n$: n 个球放入 N 个箱子, 每个箱子至多有一个球 概率
 分子: 从球 1 到球 n , 每个球有 N 种放法
 事件 A

分母: 因为每个盒子至多放一个球, 球 1 有 N 种放法, 球 2 有 $N-1$ 种, ...

$$P_N^n = N(N-1)(N-2) \cdots (N-n+1)$$

用途 1: 生日悖论: 50 个人至少 2 人生日相同的概率

用途 2: 商品推荐, 商品 A (强相关) 随机生成 $0 \sim 0.8$ 的分数, 商品 B (增加新颖度) 随机生成 $0 \sim 0.2$ 的分数, $B > A$ 的概率



$$P(B > A) = \frac{1}{1+7} = 0.125$$

④ 熵: $H(P) = -\sum_{n=1}^K (P_n \ln P_n)$ 熵越高表示混乱程度越高; 熵越低混乱程度越低
 (H(P) 越高相当于分到 K 个类别概率均等, 即完全混乱)
 取最高值

$H(P)$ 是装箱问题 (n 个物品装 K 个箱子有多少种装法) 让 $N \rightarrow +\infty$ 时的极限值

装箱问题: $\frac{n!}{n_1! n_2! \cdots n_K!}$ n 个物品, n_1, n_2, \dots, n_K 是箱子 $1, 2, \dots, K$ 的容量

分 2 箱, 分法是 $C_n^{n_1} = \frac{n!}{n_1! (n-n_1)!} = \frac{n!}{n_1! n_2!}$) 推广到分 n 个箱子

\rightarrow 因为 $\lim_{N \rightarrow \infty} \ln(N!) = N(\ln N - 1)$

$$\frac{1}{n} \ln \left(\frac{n!}{n_1! n_2! \cdots n_K!} \right) = -\sum_{k=1}^K \left[\frac{n_k}{n} \ln \frac{n_k}{n} \right] = -\sum_{k=1}^K (P_k \ln P_k) = H(P)$$

⑤ 概率和直观有时相违背。9点概率(本福特定律), 公路堵车模型

⑥ 条件概率: $P(Y|X) = P(Y, X) / P(X)$

全概率公式: $P(Y) = \sum_i P(Y|X_i) \cdot P(X_i)$

贝叶斯公式 (Bayes)

$$P(X|Y) = \frac{P(Y|X) \cdot P(X)}{P(Y)}$$
 似然函数, 给定特征预测分类结果
 特征 (如是石投准枪靶),
 样本分类结果 (如是命中靶心)
 后验概率, 给定
 分类结果时特征取值的概率.

$$P(X_i|Y) = \frac{P(X_i, Y)}{P(Y)} = \frac{P(Y|X_i) \cdot P(X_i)}{\sum_j P(Y|X_j) \cdot P(X_j)}$$

⑦ 两点分布 (Bernoulli Distribution): 即 0-1 分布.

X	0	1
P	1-p	p

$$E(X) = 1 \cdot p + 0 \cdot q = p$$

$$D(X) = E((X - E(X))^2) = E(X^2 - 2E(X) \cdot X + (E(X))^2)$$

$$= E(X^2) - (E(X))^2 = 1^2 \cdot p - p^2 = p \cdot q$$

⑧ 二项分布 (Binomial Distribution): 参数 n, p , 对服从参数 p 的二项分布样本做 n 次试验, 即 $X = \sum_{i=1}^n X_i$ 其中 X_i 服从参数为 p 的二项分布.

$$E(X) = \sum_{i=1}^n E(X_i) = n \cdot p$$

$$D(X) = \sum_{i=1}^n D(X_i) = n \cdot p \cdot q = n \cdot p(1-p)$$

$$P(X=k) = \binom{n}{k} p^k (1-p)^{n-k}$$

\Rightarrow PPT

★ 从定义角度计算

$E(X), D(X)$

⑨ 负二项分布: 对一系列服从参数为 p 的 0-1 分布的独立实验, 持续直到 r 次成功, (成功概率)

实验次数 X 的概率:

$$P(X=x, r, p) = C_{x-1}^{r-1} \cdot p^r (1-p)^{x-r}$$

$x \in [r, r+1, \dots, \infty)$

若记 $X=k$ 为失败次数

$$P(X=k, r, p) = C_{k+r-1}^{r-1} \cdot p^r (1-p)^k \quad k \in \mathbb{N}$$

⑩ 泊松分布: 一段时间/一个空间内某事件出现的个数 $X \sim \pi(\lambda)$

↓
泊松分布参数
数学期望
方差

$$P\{X=k\} = \frac{\lambda^k}{k!} e^{-\lambda} \quad k=0,1,2,\dots, \lambda>0$$

$$E(X) = \sum_{k=0}^{\infty} k \cdot \frac{\lambda^k}{k!} e^{-\lambda} = e^{-\lambda} \sum_{k=1}^{\infty} \frac{\lambda^k}{(k-1)!} \cdot \lambda = \lambda e^{-\lambda} \cdot e^{\lambda} = \lambda$$

$$D(X) = \lambda \quad // \text{推导出 PPT}$$

泰勒展开式: $e^x = 1 + x + \frac{x^2}{2!} + \frac{x^3}{3!} + \dots + \frac{x^k}{k!} + R_k$

$$1 = \boxed{e^{-x}} + \boxed{x \cdot e^{-x}} + \boxed{\frac{x^2}{2!} \cdot e^{-x}} + \boxed{\frac{x^3}{3!} e^{-x}} + \dots + \boxed{\frac{x^k}{k!} e^{-x}} + R_n \cdot e^{-x}$$

↑ 离散分布

↓ 连续分布

就是泊松分布的
概率密度

$$P\{X=1\}$$

$$P\{X=2\}$$


$$P\{X=3\}$$

$$P\{X=k\}$$

⑪ 均匀分布: $X \sim U(a, b)$

$$f(x) = \begin{cases} \frac{1}{b-a} & a < x < b \\ 0 & \text{其它} \end{cases}$$

概率密度



$$E(X) = \int_{-\infty}^{\infty} x \cdot f(x) dx = \int_a^b \frac{1}{b-a} \cdot x \cdot dx = \frac{x^2}{2(b-a)} \Big|_a^b = \frac{b+a}{2}$$

$$D(X) = E(X^2) - (E(X))^2 = \int_a^b x^2 \frac{1}{b-a} dx - \left(\frac{a+b}{2}\right)^2 = \frac{(b-a)^2}{12}$$

⑫ 指数分布 (Exponential Distribution)

$$f(x) = \begin{cases} \frac{1}{\theta} e^{-\frac{x}{\theta}} = \lambda e^{-\lambda x} & x > 0 \\ 0 & x \leq 0 \end{cases}$$

概率密度

参数: $\lambda = \frac{1}{\theta}$ (在 $(-\infty, +\infty)$ 内分布)

无记忆性:

$$\text{eg. } P(X > s+t | X > s) = P(X > t)$$

电子元件使用 t 小时故障
与使用 s 小时后再使用 t 小时
故障概率相同

$$E(X) = \int_{-\infty}^{+\infty} x \cdot f(x) dx = \int_0^{+\infty} x \cdot \frac{1}{\theta} e^{-\frac{x}{\theta}} dx = \dots = \theta$$

$$D(X) = \dots = \theta^2$$

(不是所有均等都
符合或可验证要求建
模或指数分布的)


站台人数 \sim 泊松分布

人的等待时间 \sim 指数分布

① 正态分布. $X \sim N(\mu, \sigma^2)$, μ 表示分布中心, σ^2 是方差, $\frac{1}{\sigma^2}$ 是精度
(在分布中心处取值)

$$f(x) = \frac{1}{(\sqrt{\sigma^2}) \cdot \sigma} e^{-\frac{(x-\mu)^2}{2\sigma^2}} \quad \sigma > 0, -\infty < x < +\infty$$

概率密度



$$E(X) = \int_{-\infty}^{+\infty} x \cdot \frac{1}{(\sqrt{\sigma^2}) \cdot \sigma} e^{-\frac{(x-\mu)^2}{2\sigma^2}} dx$$

$$= \int_{-\infty}^{+\infty} (\mu + \sigma t) \cdot \frac{1}{(\sqrt{\sigma^2}) \cdot \sigma} e^{-\frac{1}{2}t^2} d(\mu + \sigma t) \quad \begin{cases} \frac{x-\mu}{\sigma} = t \\ x = \mu + \sigma \cdot t \end{cases}$$

二元正态分布 $\rightarrow \begin{bmatrix} \sigma_{xx}^2 & \sigma_{xy}^2 \\ \sigma_{yx}^2 & \sigma_{yy}^2 \end{bmatrix}$



② 两点/二项/泊松/均匀/指数/正态分布参数, 数学期望, 方差.

两点 $0 < p < 1 \quad E(X) = p \quad D(X) = p(1-p)$

二项 $n \geq 1, 0 < p < 1 \quad E(X) = np \quad D(X) = n \cdot p \cdot (1-p)$

泊松 $\lambda > 0 \quad E(X) = \lambda \quad D(X) = \lambda$

均匀 $a < b \quad E(X) = \frac{1}{2}(a+b) \quad D(X) = (b-a)^2/12$

指数 $\theta > 0 \quad E(X) = \theta \quad D(X) = \theta^2$


正态 $\mu, \sigma > 0 \quad E(X) = \mu \quad D(X) = \sigma^2$

Beta分布 $\alpha, \beta \quad E(X) = \frac{\alpha}{\alpha+\beta}$

⑮ Beta分布与Gamma函数

a) 抛物线 $l(x) = \begin{cases} x^{\alpha-1} \cdot (1-x)^{\beta-1} & \langle \text{正} \rangle \\ x^{\alpha-1} \cdot (1-x)^{\beta-1} & \langle \text{左偏} \rangle \\ x^{\beta-1} \cdot (1-x)^{\alpha-1} & \langle \text{右偏} \rangle \end{cases} \quad x \in [0, 1]$

$\alpha=2, 2, 3 \quad \beta=2, 3, 2$



b) 抛物线下面积: $B(\alpha, \beta) = \int_0^1 x^{\alpha-1} (1-x)^{\beta-1} dx = \frac{\Gamma(\alpha)\Gamma(\beta)}{\Gamma(\alpha+\beta)}$

Gamma函数: $\Gamma(x) = \int_0^\infty t^{x-1} e^{-t} dt = (x-1)!$ 阶乘在实数域推广

c) 概率密度: 抛物线数值除以抛物线下面积, 值域落在 $[0, 1]$

$$f(x) = \begin{cases} \frac{1}{B(\alpha, \beta)} x^{\alpha-1} (1-x)^{\beta-1} & x \in [0, 1] \\ 0 & \text{其它} \end{cases}$$

d) 数学期望

$$E(x) = \int_0^1 x \cdot \frac{1}{B(\alpha, \beta)} x^{\alpha-1} (1-x)^{\beta-1} dx = \boxed{\frac{\alpha}{\alpha+\beta}}$$

决定左偏/右偏程度

④ 指数族 (the exponential family) 函数可写成

$$f(x) = b(x) \cdot e^{\eta \cdot g(x) - \alpha(\eta)} \rightarrow (\text{natural parameter / canonical parameter})$$

$$\text{即 } \underbrace{b(x)}_{\text{归一化}} \cdot \exp(\underbrace{\eta^T T(x)}_{\text{连接函数}} - \underbrace{\alpha(\eta)}_{\text{log partition function}})$$

sufficient statistic

log partition function

$e^{-\alpha(\eta)}$: normalization constant
正则化系数

<a> 贝努里 (二项) 分布 写成指数族: 得到 sigmoid 函数.

$$f(x) = p^x (1-p)^{1-x}$$

概率密度

$$= \exp(\ln(p^x (1-p)^{1-x}))$$

$$= \exp(x \ln p + (1-x) \ln(1-p)) = \exp((\ln \frac{p}{1-p})x + \ln(1-p))$$

记为 η , $\eta = \ln \frac{p}{1-p}$

$$\eta = \ln \frac{p}{1-p}$$

$$\text{推出 } p = \frac{1}{1+e^{-\eta}} \quad // \text{sigmoid 函数}$$

$$= \frac{1}{1+e^{-\sum \theta_i x_i}}$$

$$= 1 \cdot \exp((\ln \frac{p}{1-p}) \cdot x + \ln(1-p))$$

$$b(x)=1$$

$$\eta = \ln \frac{p}{1-p}$$

$$T(x)=x$$

$$\alpha(\eta) = \ln(1+e^\eta)$$

$$\alpha(\eta) = \ln(1-p)$$

$$= \ln(1+e^\eta)$$

把 $\eta = \ln \frac{p}{1-p}$ 建模成 $\sum_{i=1}^n \theta_i x_i$ 即特征的线性组合, 这是 LR

 高斯分布 (Gaussian) 也能写成指数族

$$f(x) = \frac{1}{\sqrt{2\pi}} e^{-\frac{1}{2}(x-\mu)^2} = \frac{1}{\sqrt{2\pi}} \exp(-\frac{1}{2}(x-\mu)^2)$$

概率密度

$$= \frac{1}{\sqrt{2\pi}} \exp(-\frac{1}{2}x^2) \cdot \exp(\mu x - \frac{1}{2}\mu^2)$$

贝努里分布被建模为 LR

高斯分布被建模为线性回归

$$b(x) = \frac{1}{\sqrt{2\pi}} \exp(-\frac{x^2}{2})$$

归一化

$$\eta = \mu$$

连接值

$$T(x) = x$$

连接函数

$$\alpha(\eta) = \frac{-\mu^2}{2} = -\frac{\eta^2}{2}$$

⑮ 事件独立: $P(AB) = P(A) \cdot P(B)$ $P(A|B) = P(A)$

$$I(A, B) = 0$$

互信息: A, B 相互包含的信息量

⑯ 数学期望: $E(x) = \sum_i x_i p_i$ (*离散事件*)

$$E(x) = \int_{-\infty}^{+\infty} x f(x) dx \quad (*连续概率*)$$

$$E(kX) = k E(X)$$

$$E(X+Y) = E(X) + E(Y)$$

$$E(XY) = E(X)E(Y) \quad (*当且仅当 X, Y 相互独立*)$$

⑰ 方差: $Var(X) = E\{[X - E(X)]^2\} = E(X^2) - E^2(X)$

$$Var(c) = 0$$

$$Var(X+c) = Var(X)$$

$$Var(kX) = k^2 Var(X)$$

$$Var(X+Y) = Var(X) + Var(Y)$$

⑱ 协方差: $Cov(X, Y) = E\{[X - E(X)][Y - E(Y)]\} = E(XY) - E(X)E(Y)$

$$Cov(X, Y) = Cov(Y, X)$$

$$Cov(aX+b, cY+d) = a \cdot c \cdot Cov(X, Y)$$

$$Cov(X_1+X_2, Y) = Cov(X_1, Y) + Cov(X_2, Y)$$

是两个随机变量 (X, Y) 具有相同方向变化趋势的程度

$Cov(X, Y) > 0$ 变化趋势相同 (X 增大, Y 也增大)

$Cov(X, Y) = 0$ 不相关

$Cov(X, Y) < 0$ 变化趋势相反

协方差上界

$$|Cov(X, Y)|^2 \leq Var(X) \cdot Var(Y) \quad \text{当且仅当 } X = kY + b \text{ 时取等号}$$

$$Cov^2(X, Y) = [E((X - E(X))(Y - E(Y)))]^2 \quad \text{协方差定义}$$

$$\leq E((X - E(X))^2 (Y - E(Y))^2) \quad \text{方差性质}$$

$$\leq E((X - E(X))^2) E((Y - E(Y))^2) \quad \text{期望性质}$$

$$= Var(X) Var(Y)$$

证明见PPT

② 皮尔逊相关系数 (Pearson)

X 与 Y 不相关, 说明 X, Y 没有线性关系, 但不保证没有其它数学关系.

(协方差, 方差层面的相关度)

因此只能称为二阶独立, 不保证 X, Y 相互独立.

但如果 X, Y 是二维正态随机变量 (已固定为正态分布): 不相关 \Leftrightarrow 相互独立

↓ 这还是在协方差, 方差层面的相关度

用皮尔逊相关系数来度量 (其实算是归一化之后的协方差)

$$\rho_{xy} = \frac{\text{Cov}(X, Y)}{\sqrt{\text{Var}(X) \text{Var}(Y)}} \leq 1$$

根据协方差上界定理.

↓ 对 n 个随机变量 (X_1, X_2, \dots, X_n)

② 协方差矩阵: 用任意两个元素 X_i, X_j 的协方差

$$C = \begin{bmatrix} \text{Cov}(X_1, X_1), \text{Cov}(X_1, X_2), \dots, \text{Cov}(X_1, X_n) \\ \text{Cov}(X_2, X_1), \text{Cov}(X_2, X_2), \dots, \text{Cov}(X_2, X_n) \\ \vdots \\ \text{Cov}(X_n, X_1), \text{Cov}(X_n, X_2), \dots, \text{Cov}(X_n, X_n) \end{bmatrix}$$

② 贝努里版本的大数定理: 事件 A 发生的频率 n_A/n 收敛于该事件概率 P

用途: (a) 正态分布参数估计

(b) 朴素贝叶斯做垃圾邮件分类

(c) 隐马尔可夫模型有监督参数学习

证明过程: 独立不相关 \Rightarrow 大数定理 \Rightarrow 大数定理推广 \Rightarrow 贝努里定理

② 最大似然估计: 样本 X_1, X_2, \dots, X_n 服从参数未知的独立同分布

↓ 联合概率密度.

$\theta_1, \theta_2, \dots, \theta_k$ (高维分布的均值 方差 伯努利分布的 p ...)

$$\underbrace{L(X_1, X_2, \dots, X_n)}_{\text{固定}}(\underbrace{\theta_1, \theta_2, \dots, \theta_k}_{\text{未知}}) = \prod_{i=1}^n \underbrace{f(X_i, \theta_1, \theta_2, \dots, \theta_k)}_{\text{固定}}$$

↓
找到让这个联合概率密度上取最大值的参数 $\theta_1, \theta_2, \dots, \theta_k$

就是最大似然估计

② 最大似然估计求解：求函数 L 最大值，需求导， $\prod_{i=1}^n f(x_i, \theta_1, \dots, \theta_k)$ 求导不方便求导 \Rightarrow 对 $\log(L)$ 对数似然函数求最大值

$$\log L(\theta_1, \theta_2, \dots, \theta_k) = \sum_{i=1}^n \log f(x_i, \theta_1, \dots, \theta_k)$$

$$\frac{\partial L(\theta)}{\partial \theta_i} = 0, i = 1, 2, \dots, k$$

求偏导，让偏导为0得到驻点，分析该驻点，是极大点

③ 例子：对高斯分布做最大似然估计

$$f(x) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x-\mu)^2}{2\sigma^2}}$$

$$L(x) = \prod_{i=1}^n \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x_i-\mu)^2}{2\sigma^2}}$$

$$l(x) = \log(L(x)) = \sum_{i=1}^n \log \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x_i-\mu)^2}{2\sigma^2}}$$

对数似然函数

$$= \sum_{i=1}^n \log \frac{1}{\sqrt{2\pi}\sigma} + \sum_{i=1}^n \log (e^{-\frac{(x_i-\mu)^2}{2\sigma^2}})$$

$$= \sum_{i=1}^n \log \frac{1}{\sqrt{2\pi}\sigma} + \sum_{i=1}^n -\frac{(x_i-\mu)^2}{2\sigma^2}$$

$$= -\frac{n}{2} \log(2\pi\sigma^2) - \frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2$$

对 $l(x)$ 关于 σ^2, μ 求偏导，得到

$$\mu = \frac{1}{n} \sum_{i=1}^n x_i \quad /* \text{样本均值} */$$

$$\sigma^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \mu)^2 \quad /* \text{样本的伪方差} */$$

结论：样本的均值即高斯分布的期望

样本的伪方差即高斯分布的方差

用于 EM 算法，高斯混合模型

④ 过拟合惩罚系数

$$P_{男} = \frac{N_{男} + 5}{N_{男} + N_{女} + 10}$$

$$P_{女} = \frac{N_{女} + 5}{N_{男} + N_{女} + 10}$$


更多内容见拉普拉斯平滑

② 偏度, 峰度, T函数, 熵

* 偏度: 度量随机变量(相对于均值)概率分布的不对称性

偏度为

- 正: 表示正偏, 长尾在右侧
- 零: 相对均匀地分布在均值两侧 (不保证对称)
- 负: 表示负偏, 长尾在左侧



偏度公式: 三阶矩量数与二阶矩量数1/3次方的比

$$\gamma_1 = E\left[\left(\frac{X-\mu}{\sigma}\right)^3\right] = \frac{E[(X-\mu)^3]}{E[(X-\mu)^2]^{3/2}} = \frac{K_3}{K_2^{3/2}}$$

用 $\text{Skew}[X]$ 表示偏度

$$\gamma_1 = E\left[\left(\frac{X-\mu}{\sigma}\right)^3\right] = \frac{E[X^3] - 3\mu E[X^2] + 2\mu^2 E[X] - \mu^3}{\sigma^3}$$

* 峰度: 度量概率密度在均值处峰值高低

峰度公式: 4阶中心矩除以方差的平方减3 (减3为了让正态分布峰度为0)

$$\gamma_2 = \frac{K_4}{K_2^2} = \frac{\mu_4}{\sigma^4} - 3 = \frac{\frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^4}{\left(\frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2\right)^2} - 3$$

超峰度为

- 正: 尖峰态 (也被称为超峰度 (excess kurtosis))
- 零: 正态分布
- 负: 低峰态

* 标准正态分布的超峰度为3, 峰度为0, 偏度为0, 我记过PPT

* T函数: $\Gamma(x) = (x-1)\Gamma(x-1) \Rightarrow \frac{\Gamma(x)}{\Gamma(x-1)} = x-1$ 阶乘在实数域推广

* Pearson 相关系数: $\rho_{XY} = \frac{\text{Cov}(X,Y)}{\sqrt{\text{Var}(X)\text{Var}(Y)}}$ X与Y线性相关时取等号

* FFT 变换

* 卷积及应用示例