

SVM: 支持向量机: hard margin, soft margin, kernel function
 (线性可分SVM) (线性SVM) (解决线性不可分问题)
 (核函数)

① 线性可分向量机

<a> 过程概要:

分割正负样本的超平面: $\vec{w} \cdot \vec{x} + b = 0$

如果有样本的标注值 (标值) (正样本: 1, 负样本: -1)

$$\frac{y^{(i)} \cdot (\vec{w}^T \vec{x}^{(i)} + b)}{\|\vec{w}\|}$$

预测正确: > 0 正*正 or 负*负
 预测错误: < 0 正*负 or 负*正

将样本 \vec{x}_i 代入 $\vec{w} \cdot \vec{x} + b$, 值
 $\begin{cases} > 0: \text{样本在超平面法线正向} \\ = 0: \text{在超平面上} \\ < 0: \text{在法线负方向} \end{cases}$
 样本 \vec{x}_i 到超平面距离 $\frac{|\vec{w}^T \vec{x}_i + b|}{\|\vec{w}\|} = d(x_i, l)$

优化目标: 找到超平面 l_j

$$\text{使得 } \max_j \left(\min_{i \in \{1, n\}} d(x^{(i)}, l_j) \right)$$

(样本到超平面的最小距离) \rightarrow 能够最大

 建模


分离超平面: $\vec{w}^T \Phi(x) + b = 0$

其中 $\Phi(x)$ 是核函数, 作特征空间转换, 把 x 映射到更高维度

分类决策函数: $f(x) = \text{sign}(\vec{w}^T \Phi(x) + b)$
 $\begin{cases} > 0: \text{在正的半空间} \\ < 0: \text{在负的半空间} \end{cases}$

<c> 线性可分向量机

v.s. 线性向量机



引入松弛因子
 放弃一部分样本
 得到更大的分类间隔

<d> 求解线性可分 SVM: 用 Lagrange 乘子法

~~Optimization Problem~~

$$\arg \max_{w, b} \left\{ \frac{1}{\|\vec{w}\|} \min_i [y_i \cdot (\vec{w}^T \cdot \Phi(x_i) + b)] \right\}$$

优化目标
 转为

让②取最小值 (只关心支持向量)
 忽略 C

$$\arg \max_{w, b} \frac{1}{\|\vec{w}\|}$$

不论值是多少, 都可以通等比缩放

$$y_i (\vec{w}^T \cdot \Phi(x_i) + b) \geq C \quad ①$$

$$\|\vec{w}\| \leq C \quad ② \quad \text{来让 ①/② 值保持不变}$$

(与求 $\|\vec{w}\|$ 最优解无关)
 可忽略

$$\boxed{\text{同时让 } ① \geq 1}$$

问题转化为

$$\text{求解 } \max_{w, b} \frac{1}{\|w\|} \quad \text{s.t. } y_i \cdot (w^T \cdot \phi(x_i) + b) \geq 1, \quad i=1, 2, \dots, n$$

$$\text{等价于 } \min_{w, b} \frac{1}{2} \|w\|^2 \quad \text{s.t. } y_i \cdot (w^T \cdot \phi(x_i) + b) \geq 1, \quad i=1, 2, \dots, n$$

$$\text{拉格朗日函数 } \mathcal{L}(w, b, \alpha) = \frac{1}{2} \|w\|^2 - \sum_{i=1}^n \alpha_i (y_i (w^T \cdot \phi(x_i) + b) - 1)$$

↑
拉格朗日乘子

原问题: $\min_{w, b} \max_{\alpha} \mathcal{L}(w, b, \alpha)$ 求解最大值的最小值

↓ 需满足KKT条件

对偶问题: $\max_{\alpha} \min_{w, b} \mathcal{L}(w, b, \alpha)$ 求解最小值的最大值

对 w, b 求偏导, 令偏导为 0

$$\frac{\partial \mathcal{L}}{\partial w} = \frac{1}{2} \cdot 2w - \sum_{i=1}^n \alpha_i y_i \phi(x_i) \rightarrow 0 \Rightarrow w = \sum_{i=1}^n \alpha_i y_i \phi(x_i)$$

$$\frac{\partial \mathcal{L}}{\partial b} = -\sum_{i=1}^n \alpha_i y_i \rightarrow 0 \Rightarrow \sum_{i=1}^n \alpha_i y_i = 0$$

代入拉格朗日函数

$$\mathcal{L}(w, b, \alpha) = \frac{1}{2} \|w\|^2 - \sum_{i=1}^n \alpha_i (y_i (w^T \cdot \phi(x_i) + b) - 1)$$

$$= \frac{1}{2} w^T w - w^T \sum_{i=1}^n \alpha_i y_i \phi(x_i) - b \underbrace{\sum_{i=1}^n \alpha_i y_i}_{=0} + \sum_{i=1}^n \alpha_i$$

$$= \frac{1}{2} \left(\sum_{i=1}^n \alpha_i y_i \phi(x_i) \right)^T \left(\sum_{i=1}^n \alpha_i y_i \phi(x_i) \right) - \sum_{i=1}^n \alpha_i y_i \phi(x_i)^T \sum_{i=1}^n \alpha_i y_i \phi(x_i) + \sum_{i=1}^n \alpha_i$$

$$= -\frac{1}{2} \left(\sum_{i=1}^n \alpha_i y_i \phi(x_i) \right)^T \left(\sum_{i=1}^n \alpha_i y_i \phi(x_i) \right) + \sum_{i=1}^n \alpha_i$$

根据对偶
问题求 max

$$= \sum_{i=1}^n \alpha_i - \frac{1}{2} \sum_{i,j=1}^n \alpha_i \alpha_j y_i y_j \phi^T(x_i) \phi(x_j)$$

|| 已经只有样本和 α_i 了
可以求解 α_i 了

$$\alpha_i^* = \arg \max_{\alpha_i} \left(\sum_{i=1}^n \alpha_i - \frac{1}{2} \sum_{i,j=1}^n \alpha_i \alpha_j y_i y_j \phi^T(x_i) \phi(x_j) \right)$$

$$\text{求解 } \max_{\alpha} \left(\sum_{i=1}^n \alpha_i - \frac{1}{2} \sum_{i,j=1}^n \alpha_i \alpha_j y_i y_j (\phi(x_i) \cdot \phi(x_j)) \right) \quad \text{s.t. } \sum_{i=1}^n \alpha_i y_i = 0 \quad \alpha_i \geq 0$$

$$\text{等价于 } \min_{\alpha} \left(\frac{1}{2} \sum_{i,j=1}^n \alpha_i \alpha_j y_i y_j (\phi(x_i) \cdot \phi(x_j)) - \sum_{i=1}^n \alpha_i \right) \quad \text{s.t. } \sum_{i=1}^n \alpha_i y_i = 0 \quad \alpha_i \geq 0$$

对 α_i 求偏导, 梯度下降.

也可以用 SMO 算法, 固定任意 $n-2$ 个 α_i , 只变化其中 2 个, 让其下降更快, 不断迭代, 穷举化求解

解出 α_i^* 之后，代入公式解出 w^* , b^* (只有支持向量经过的样本 $\alpha_i \neq 0$)

$$w^* = \sum_{i=1}^N \alpha_i^* y_i \phi(x_i) \quad \text{上一节公式} \otimes$$

$$b^* = y_i - \sum_{i=1}^N \alpha_i^* y_i (\phi(x_i) \cdot \phi(x_j)) \quad \text{②} \rightarrow \text{代入支持向量算出?}$$

代入公式得到

$$\text{分离超平面} \quad w^* \phi(x) + b^* = 0$$

$$\text{分类决策函数} \quad f(x) = \text{sign}(w^* \phi(x) + b^*)$$


② 例子: 见 ppt

↑ 上一小节的算法

② 线性 SVM: 线性可分 SVM ($d < \infty$) 中 希望 $\min_{i \in [1, N]} d(x^{(i)}, L_j) = \min_{i \in [1, N]} \frac{|w^T \phi(x_i)^T + b|}{\|w\|}$ 取最大

考虑样本标注时, 我们希望 $\min_{i \in [1, N]} \frac{y^{(i)} \cdot (w^T \phi(x^{(i)})^T + b)}{\|w\|}$ 取最大

不恰标注 $\min_{i \in [1, N]} \frac{y^{(i)} (w^T \phi(x^{(i)})^T + b)}{\|w\|} = d_0$



分离超平面

$$y^{(i)} (w^T \phi(x^{(i)})^T + b) \geq d_0 \|w\|$$

取值为 +1, -1

对 w 等比缩放, 总能找到一个 w' , 使得

$$y^{(i)} (w'^T \phi(x^{(i)})^T + b) \geq 1$$

而在 线性 SVM, 为每个样本 x_i 指定一个松弛因子 ξ_i , 约束条件变为

本节算法

$$y^{(i)} (w'^T \phi(x^{(i)})^T + b) \geq 1 - \xi_i$$

目标函数也由 $\min_{w, b} \frac{1}{2} \|w\|^2$ 变为

$$\min_{w, b} \left(\frac{1}{2} \|w\|^2 + C \sum_{i=1}^N \xi_i \right)$$

权重

松弛因子也作损失项, 加入到优化目标中, 期望其最小

作用类似于 LR, 线性回归的正则项



此处是有更宽的分类间隔
受噪声的干扰

<a> 加入松弛因子以后的约束条件与求极值问题

$$\min_{w, b, \xi} \frac{1}{2} \|w\|^2 + C \sum_{i=1}^N \xi_i \quad \text{s.t.} \begin{cases} y_i(w \cdot x_i + b) \geq 1 - \xi_i & i=1, 2, \dots, n \\ \xi_i \geq 0 & i=1, 2, \dots, n \end{cases}$$

拉格朗日函数

值越小，分类间隔
宽度越大，拟合拟合越强

$$\mathcal{L}(w, b, \xi, \alpha, \mu) = \frac{1}{2} \|w\|^2 + C \sum_{i=1}^N \xi_i - \sum_{i=1}^N \alpha_i (y_i(w \cdot x_i + b) - 1 + \xi_i) - \sum_{i=1}^N \mu_i \xi_i$$

对 w, b, ξ 求偏导，令偏导为 0，得到

$$w = \sum_{i=1}^n \alpha_i y_i \phi(x_i)$$

$$0 = \sum_{i=1}^n \alpha_i y_i$$

$$C - \alpha_i - \mu_i = 0$$

$$\left\{ \begin{array}{l} \text{原问题: } \min_{w, b, \xi} \max_{\alpha} \mathcal{L}(w, b, \xi, \alpha, \mu) \\ \text{对偶问题: } \max_{\alpha} \min_{w, b, \xi} \mathcal{L}(w, b, \xi, \alpha, \mu) \end{array} \right.$$

参考①的推导

将三式代入 $\mathcal{L}(w, b, \xi, \alpha, \mu)$ ，得到

$$\min_{w, b, \xi} \mathcal{L}(w, b, \xi, \alpha, \mu) = -\frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n \alpha_i \alpha_j y_i y_j (x_i \cdot x_j) + \sum_{i=1}^n \alpha_i$$

接下来对 α 求 \max

$$\max_{\alpha} \min_{w, b, \xi} \mathcal{L}(w, b, \xi, \alpha, \mu) = \max_{\alpha} \left(-\frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n \alpha_i \alpha_j y_i y_j (x_i \cdot x_j) + \sum_{i=1}^n \alpha_i \right)$$

$$\text{s.t.} \sum_{i=1}^n \alpha_i y_i = 0$$

$$\left\{ \begin{array}{l} C - \alpha_i - \mu_i = 0 \\ \alpha_i \geq 0 \\ \mu_i \geq 0 \quad i=1, 2, \dots, n \end{array} \right\} \Leftrightarrow \boxed{0 \leq \alpha_i \leq C}$$

把负号提出，整理约束条件，上式等价于求

$$\min_{\alpha} \left(\sum_{i=1}^n \sum_{j=1}^n \alpha_i \alpha_j y_i y_j (x_i \cdot x_j) - \sum_{i=1}^n \alpha_i \right) \quad \text{s.t.} \begin{cases} C - \alpha_i - \mu_i = 0 \\ 0 \leq \alpha_i \leq C \end{cases}$$

对 α_i 求偏导，梯度下降，得到最优的 α^* (与线性可分 SVM 类似，必取各种值)

代入到公式②中，得到 $w^* = \sum_{i=1}^n \alpha_i^* y_i x_i$

使用满足 $0 < \alpha_i < C$ 的向量，实践中经常取支持向量的均值作为 b^*

$$\rightarrow b^* = \frac{1}{2} \left(\max_{i: y_i = -1} w^* \cdot x_i + \min_{i: y_i = 1} w^* \cdot x_i \right)$$

负例 正例

求得分离超平面 $w^* x + b^* = 0$

求得分类决策函数 $f(x) = \text{sign}(w^* x + b^*)$


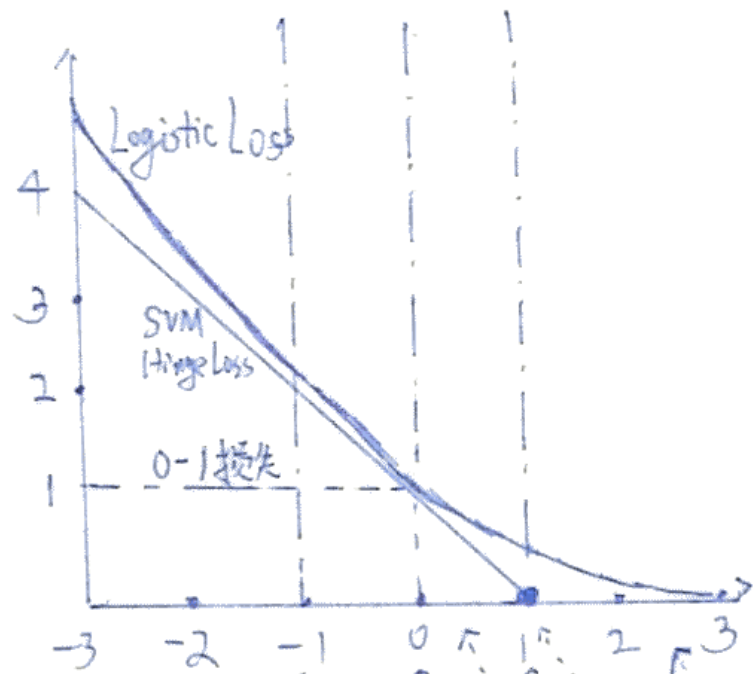
线性SVM损失函数分析

前面推导过程中用到约束条件

得到 $\begin{cases} u_i \geq 0 \\ \alpha_i = C - u_i \in [0, C] \end{cases}$

X_i 约束条件的系数, 即 $y_i \cdot (W \cdot X_i + b) \geq 1 - \xi_i$ 的拉格朗日乘子
 \uparrow ξ_i 系数, 即 $\xi_i \geq 0$ 的拉格朗日乘子

$C = \alpha_i + u_i, u_i \geq 0$



- ① X_i 在支撑面正上方: $\alpha_i = 0, \xi_i = 0$, (不需松弛)
 (不是支撑向量, SVM 不关心)
 ② X_i 在分对支撑面上: $0 < \alpha_i < C, \xi_i = 0$ (是支撑向量) (不需松弛)
 ③ X_i 在分隔超平面, 分对支撑面之间:
 $\alpha_i = C; 0 < \xi_i < 1$ (需松弛)
 ④ X_i 在分隔超平面负方向
 $\alpha_i = C; \xi_i > 1$

为了让 $u_i \xi_i = 0$ 而 $\xi_i > 0$
 $\Rightarrow u_i$ 必须为 0
 $\Rightarrow \alpha_i = C - u_i = C$

0-1 损失: 分对无损失, 分错损失值为 1 (每个样本)

Logistic Loss: 分对 (即使在支撑面正方向) 也会有可能有一定损失, 只是损失值小

SVM Hinge Loss: ~~分对也有损失~~ 支撑面正方向就无损失

分对但落下支撑面下方 (需松弛) 有 < 1 的损失
 分错有 1 的损失, 错得越离谱损失越大
 (但是是线性的)

eg: $\Phi(x, x_1, \dots)$

$$\begin{bmatrix} x_1 x_1 \\ x_1 x_2 \\ \vdots \\ x_1 x_n \\ \sqrt{2c} x_1 \\ \sqrt{2c} x_2 \\ \sqrt{2c} x_3 \\ \vdots \\ c \end{bmatrix}$$


③核函数: 将原始特征映射到新的特征空间, 解决线性不可分问题

多项式核函数 (以 $d=2$ 为例): $\Phi(\vec{x}) = \left(\underset{\text{数组}}{\text{vec}(x_i x_j)} \Big|_{i,j=1}^n, \text{vec}(\sqrt{2c} x_i) \Big|_{i=1}^n, c \right)$

推导来源: $k(\vec{x}, \vec{y}) = (\vec{x} \cdot \vec{y} + c)^2 = (\vec{x} \cdot \vec{y})^2 + 2c\vec{x} \cdot \vec{y} + c^2$

高维衰减快: $= \sum_{i=1}^n \sum_{j=1}^n (x_i x_j)(y_i y_j) + \sum_{i=1}^n (\sqrt{2c} x_i \cdot \sqrt{2c} y_i) + c^2$

值越大, 精度越高, 拟合能力越强: $= \Phi(\vec{x})^T \Phi(\vec{y})$ ----- 导出 -----



高斯核函数: $\Phi(\vec{x}) = e^{-\frac{x^2}{2\sigma^2}} \left[1, \frac{1}{\sqrt{1!}} \frac{x}{\sigma}, \frac{1}{\sqrt{2!}} \frac{x^2}{\sigma^2}, \frac{1}{\sqrt{3!}} \frac{x^3}{\sigma^3}, \dots, \frac{1}{\sqrt{n!}} \frac{x^n}{\sigma^n}, \dots \right]$

映射到了
无穷维
理论上不可解
实际用高斯核
RBF可解

推导来源: $k(\vec{x}, \vec{y}) = e^{\frac{\|\vec{x}-\vec{y}\|^2}{2\sigma^2}} = e^{-\frac{(\vec{x}-\vec{y})^2}{2\sigma^2}} = e^{-\frac{x^2+y^2}{2\sigma^2}} \cdot e^{\frac{xy}{\sigma^2}}$ 泰勒展开

$$= e^{-\frac{x^2+y^2}{2\sigma^2}} \left(1 + \frac{1}{\sigma^2} \frac{xy}{1!} + \left(\frac{1}{\sigma^2}\right)^2 \frac{(xy)^2}{2!} + \left(\frac{1}{\sigma^2}\right)^3 \frac{(xy)^3}{3!} + \dots + \left(\frac{1}{\sigma^2}\right)^n \frac{(xy)^n}{n!} + \dots \right)$$

$$= e^{-\frac{x^2+y^2}{2\sigma^2}} \left(1 + \frac{1}{1!} \frac{x}{\sigma} \frac{y}{\sigma} + \frac{1}{2!} \frac{x^2}{\sigma^2} \frac{y^2}{\sigma^2} + \frac{1}{3!} \frac{x^3}{\sigma^3} \frac{y^3}{\sigma^3} + \dots + \frac{1}{n!} \frac{x^n}{\sigma^n} \frac{y^n}{\sigma^n} + \dots \right)$$

$= \Phi(x)^T \Phi(y)$ ----- 导出 -----

Sigmoid 核函数: 推导来源 $k(x, y) = \tanh(x \cdot y + c)$

选择核函数: 往往要依赖先验领域知识 / 交叉验证等方案

没有先验知识时可以无脑使用高斯核, 发现过拟合再退回到多项式核

④ SVM SMO (Sequential Minimal Optimization): 序列最小最优化系数求解

SVM 系数求解时, 有多个拉格朗日乘子, 每次只选择其中两个乘子做优化, 其他因子认为是常数 (将 N 个解问题, 转成两个变量求解问题)

求这个函数时


$$\min_{\alpha} \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j y_i y_j K(x_i, x_j) - \sum_{i=1}^N \alpha_i$$

s.t. $\sum_{i=1}^N \alpha_i y_i = 0$

$0 \leq \alpha_i \leq C$

改为求解

$$\min_{\alpha_1, \alpha_2} W(\alpha_1, \alpha_2) = \frac{1}{2} K_{11} \alpha_1^2 + \frac{1}{2} K_{22} \alpha_2^2 + y_1 y_2 \alpha_1 \alpha_2 K_{12} - (\alpha_1 + \alpha_2) + y_1 \alpha_1 \sum_{i=3}^N y_i \alpha_i K_{1i} + y_2 \alpha_2 \sum_{i=3}^N y_i \alpha_i K_{2i}$$



s.t. $\alpha_1 + \alpha_2 + \dots + \alpha_N = 0$ $0 \leq \alpha_i \leq C$

⑤ SVR: SVM用于回归

⑥ SVM用于多分类 (How?)

⑦ AUC

预测 \ 实际	Positive	Negative
正	TP ✓	FN ✗
负	FP ✗	TN ✓

$$TPR = \frac{TP}{TP + FN}$$
 (true positive rate) (真正例比例)

$$FPR = \frac{FP}{FP + TN}$$
 (false positive rate) (假正例比例)


$$accuracy = \frac{TP + TN}{TP + TN + FN + FP}$$

$$precision = \frac{TP}{TP + FP}$$

$$recall = \frac{TP}{TP + FN}$$

$$F_1 = \frac{2 \cdot precision \cdot recall}{precision + recall}$$

$$F_\beta = \frac{(1 + \beta^2) \cdot precision \cdot recall}{\beta^2 \cdot precision + recall}$$



★ (FPR=0.1, TPR=0.8):
 以 0.1 的负例预测为正例的代价 (10%)
 换来 0.8 的正例预测为正例的效果 (80%)

(预测为正)
(真正例比例)

预测为正的样本中百分之多少是正确预测的

总的正样本中, 有多少能被预测出来